

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
EKONOMETRINĖS ANALIZĖS KATEDRA

Monika ŠEŠTOKAITĖ ir Simona PLONYTĖ

CAPM ir akcijų portfelio konstravimas

Kursinio darbo vadovas prof. Remigijus LEIPUS

Ekonometrija, III kursas, I grupė

VILNIUS 2011

Turinys

1 Įvadas

2 CAPM

3 Duomenys

3.1 JAV 30-ies dienų išdo vekseliai

JAV vieno mėnesio išdo vekselius laikysime nerizikinga investicija. Nagrinėjami dieniniai duomenys nuo 2001 rugpjūčio 1 dienos iki 2011 metų liepos pabaigos. Kadangi JAV išdo vekselių duomenys pateikti kaip dieninė diskonto norma antrinėje rinkoje, vekselių pelningumą galima apskaičiuojant naudojant dvi patogias formules:

$$P = 100 - \left(100 \times \frac{d \times t}{360}\right)$$

Pirma, iš diskonto normos išreikiame kainą - iš nominalo atimtą nuolaidą. Čia nominalas = 100, P - išdo vekselio kaina, d - išdo vekselio diskonto norma, t - periodo dienų skaičius (mūsų atveju, 30 dienų). Turėdami kainą, galime rasti išdo vekselio pelningumą:

$$Y = \frac{100 - P}{P} \times \frac{365}{t}$$

Čia Y - išdo vekselio pelningumas, t.y. grąža ir t = 30.

Taigi, 1 pav. vaizduojamos JAV išdo vekselių dienos grąžos




1 pav.: JAV 30-ies dienų išdo vekselių pelningumas


Grafikas gan išraiškingai atspindi nuo 2004 metų prasidėjusį ekonomikos pakilimą, išaugusį vartojimą ir analogiškas JAV vyriausybės pastangas pritraukti investuotojus didelėmis palūkanų normomis - išdo vekselių pelningumu. Vekselių pelningumas pasiekė maksimumą 2006 metais, iki 2007 metų išlaikė gan aukštą lygį, tačiau nuo 2007 metų palaipsniui mažėjo, kol galiausiai 2008 metais išdo vekselių pelningumas nukrito iki žemiausio lygio nuo 2001 metų.

3.2 Indekso Standard & Poor's 500 akcijų dienosinės kainos ir grąžos

JAV įmonių indeksas Standard & Poor's 500 atstovaus visą ar bent didžiąją dalį Jungtinių Amerikos valstijų rinkos. Indeksą sudaro 500 įmonių, gaunančių daugiau nei dolco ženklas5 mlrd. pelną; tarp jų - Adobe Systems Inc, Amazon.com Inc, Apple Inc, Coca Cola Co. ir kitos. Indekso dienerių akcijų grąžų grafikas neblogai atspindi rinkos būklę Jungtinėse Amerikos valstijose per pastaruosius dešimt metų. Nuo 2002 metų vidurio stebimas stabilus rinkos akcijų pelningumo didėjimas, o nuo 2007 metų - stabilus, bet kiek staigesnis pelningumo mažėjimas. Taip pat gan ryškiai pastebima ir 2008-2009 metų rinkos krizė bei po jos prasidėjęs įmonių akcijų pelningumo augimas.



2 pav.: S & P 500 dienosinės akcijų kainos 2001-2011 m.




3 pav.: S & P 500 dienos akcijų gražos

Šiame grafike vaizduojamos rinkos dienos akcijų gražos. Didesnis nei vidutinis gražų dispersijos padidėjimas taip pat sutampa su 2008-2009 metų krizės laikotarpiu. Dieninės gražos stabiliausios 2003-2007 metų periodu, o tai irgi sutampa su stabilumo laikotapiu JAV ekonomikoje.


3.3 Microsoft Corp.

Viena iš CAPM modelio tyrimui pasirinktų įmonių - Microsoft Corp. Tai viena didžiausių programinę įrangą gaminančių kompanijų, turinti savo atstovybę ir Lietuvoje. Žemiau pateiktos šios įmonės dienių akcijų kainos bei dienių akcijų gražos.



4 pav.: Microsoft Corp. dienos akcijų kainos 2001-2011 m.

Microsoft Corp. akciju kainos pasizymi gan periodiskais svyravimais iki mazdaus 2005 metu pabaigos. Nuo 2006 metu akciju kaina gerokai pakilo ir 2007 metais pasieke auksciausia lygi. Bet tikriausiai sia imone irgi paveike krize ir nuo 2007 iki 2008 metu vidurio akciju kainos krito, kol pasieke zemiausia lygi. Toliau stebime stabiliu akciju kainu kilima iki 2011 vasaros.



5 pav.: Microsoft Corp. dienes akciju grazos 2001-2011 m.

Microsoft Corp. dienes akciju grazos, taip pat kaip ir Standard & Poor's, neblogai atspindi stabilumo ir krizes laikotarpius, o kelios isskirtys susijusios su kitomis/atskiromis/individualiomis imones charakteristikomis.

3.4 Apple Inc.

Kita imone, pasirinkta CAPM modelio tyrimui - Apple Inc. Tai kompanija, siulanti plataus vartojimo elektronikos ir programines įrangos produktus. Žemiau pateikti Apple Inc. dieninių akcijų kainų bei dieninių akcijų grąžų grafikai.



6 pav.: Apple Inc. dienos akcijų kainos 2001-2011 m.

Apple Inc. dienių akcijų kainų svyravimai kiek skiriasi nuo S&P 500 ar Microsoft akcijų kainų. Pastaruosius keletą metų šios kompanijos akcijų kainos stabiliai kilo ir net krizės laikotarpiu nepasiekė žemiausios kainos per dešimties metų laikotarpį. Svarbi data duomenų tyrimui - 2005 vasario 5 d. Šią dieną Apple Inc. padvigubino akcijų kiekį už tą pačią kainą, t.y. jei iki padalijimo viena akcija kainavo dolcas88, tai po padalijimo už tą pačią kainą investuotojas jau galėjo įsigyti dvi akcijas (po dolcas44 už vieną). Spėjama, jog Apple Inc. tokiu veiksmu norėjo pritraukti naujų investuotojų.



7 pav.: Apple Inc. dienos akcijų gražos 2001-2011 m.

Šiame grafike pateikiamos dienos akcijų gražos, be 891-ojo duomens (pašalinta išskirtis, atsiradusi dėl akcijų kiekio padvigubinimo). Galima


pastebėti gan stabilią, nors santykinai nemažą, duomenų dispersiją, o kelios išskirtys turbūt susijusios su atskirais/pavieniais įmonės sprendimais, įvykiais arba rezonavo su krize.

3.5 Auksas

Įdomu tyrinėti ne tik svarbių įmonių rizikos premijų priklausomybę nuo rinkos rizikos premijos, bet ir aukso pelningumą. Aukso kaina per dešimt metų stabiliai kyla be jokių ryškesnių nuosmukių. 2011 m. vasarą kaina pasiekė auksčiausią kada nors buvusį lygį.



8 pav.: Aukso dienosinės kainos



9 pav.: Aukso dienosinės gražos

Aukso dieninių grąžų grafikas turi gana mažą dispersiją, kurios padidėjimas 2008 metais sutampa su krizės laikotapiu. Tačiau net ir per krizę didžiausios aukso grąžų vertės nepasiekia 0.1 ar -0.1.

4 Aprašomoji duomenų statistika

Rizikos premija - skirtumas tarp įmonės akcijos gražos ir išdo vekselio pelningumo. Tai premija investuotojui, pasirinkusiam rizikingesnės įmonės akcijas vietoje nerizikingo išdo vekselio. Kuo ji didesnė, tuo labiau traukia investicijas, bet dažnai (pagal CAPM teoriją) didesnė premija taip pat reiškia ir didesnę riziką investuojant į tam tikrą imonę. Žemiau pateiktoje lentelėje paskaiciuosime aktyvų vidutines gražas, standartinius nuokrypius, dispersijas bei jų vidutines rizikos premijas ir standartinius nuokrypius.

Duomenys	Vidurkis	Dispersija	Standartinis nuokrypis
rkfree	0.00186004	2.789252e-06	0.001670105
market	0.0001173288	0.0001827668	0.01351913
microsoft	0.0001968397	0.0003574371	0.01890601
apple	0.001807715	0.0006370941	0.02524072
gold	0.0007931419	0.0001357824	0.01165257
mrp	-0.001742711	0.0001857122	0.01362763
microsoftrp	-0.001663201	0.0003601065	0.01897647
applerp	-5.20737e-05	0.000639531	0.02528895
goldrp	-0.001066898	0.0001384164	0.01176505

Didžiausią gražų vidurkį turi Apple Inc. (0.001807715), šis aktyvas galėtų būti investuotojams patraukliausias. Didžiausia gražų dispersija(0.0006370941)/standartinis nuokrypis(0.02524072) taip pat priklauso Apple Inc., taigi, nors šios akcijos žada ir didžiausią pelną, tai yra rizikingiausias aktyvas. Mažiausia dispersija (0.0001357824)/standartinis nuokrypis (0.01165257) priklauso aukso kainų gražoms xxx, šis aktyvas turi mažiausius svyravimus, todėl atrodo patikimai.

Koreliacijos:

market	microsoft	0.7184425
market	apple	0.5511114
market	gold	-0.04482454
mrp	microsoftrp	0.7209318
mrp	applerp	0.5534901
mrp	goldrp	-0.0266428

Labiausiai su rinka koreliuoja Microsoft Corp. (koreliacijos koeficientas lygus 0.7184425), t.y. labiausiai priklauso nuo rinkos būklės.

Mažiausiai su rinkos kainomis koreliuoja aukso kainos (-0.04482454). Šis koreliacijos koeficientas yra neigiamas, taigi tikėtina, kad rinkos akcijų vertei kintant, aukso gražos kis priešinga kryptimi, tačiau dėl nedidelės koeficiento reikšmės aktyvo kainos tuo pačiu greičiu gali ir nesikeisti. Tai ypač aktualu krizės laikotarpiu.

5 Kapitalo aktyvų įvertinimo modelis

Viena iš kapitalo aktyvų įvertinimo modelio (*Capital asset pricing model* - CAPM) išraiškų - paprasta vieno kintamojo regresija. Pasinaudojus ja, tirsiame imonių akcijų ir aukso rizikos premijų priklausomybę nuo rinkos rizikos premijų. Modeliuose pateiktas laisvasis narys α ir koeficientas β .

α	β	R^2	$p - value$
0.0000863	1.0038977	0.5197	$< 2.2e-16$

Gautas β koeficientas lygus 1.004 ir yra reikšmingas. Tai reiškia, jog rinkos rizikos premijai pakilus ar nukritus 1%, Microsoft Corp. rizikos premijos taip pat pakils 1%. Laisvasis narys beveik lygus nuliui ir nereikšmingas, tai neprieštarauja CAPM teorijai ir logikai - jei rinkos rizikos premija lygi nuliui, tai investuotojo i Microsoft Corp. šansai gauti rizikos premiją yra labai maži. $R^2 = 0.5197$, tai reiškia, kad 51,97% rinkos duomenų paaiškina Microsoft Corp. rizikos premijų svyravimus, t.y. sudaro sistemine (rinkos) riziką. Likusi specifinė rizika priklauso nuo kitų įmonės charakteristikų.

α	β	R^2	$p - value$
0.0017347	1.0269695	0.3064	$< 2.2e-16$

Koeficientas β , kaip ir Microsoft Corp. įmonės, lygus 1.027 ir yra reikšmingas ($0 < 0.005$). Taigi rinkos akcijų vertei susvyravus 1%, Apple Inc. irgi gali patirti panašų akcijų kainos pokytį. Laisvasis narys labai arti nulio ir nereikšmingas, taigi investuotojas pasirinkęs Apple Inc. akcijas negali tikėtis jokios rizikos premijos, kai rinkos akcijų vertės pokytis lygus nuliui. Visgi R^2 nėra labai didelis - tik 30% rinkos duomenų paaiškina Apple Inc. akcijų vertės svyravimus.


α	β	R^2	$p - value$
-0.0011070	-0.0230014	0.01176	0.183

Visai kitoks rezultatas gaunamas sudarius aukso rizikos premijų priklausomybės nuo rinkos rizikos premijų modelį. Šįkart $\beta = -0.023$ ir tai reikštų, kad aukso kainos ne tik mažai priklauso nuo rinkos akcijų vertės svyravimų, bet netgi juda priešinga linkme. Tai gali pasirodyti kaip itin patraukli investicija nuosmukio laikotarpiu. Tačiau koeficiento p-reikšmė $= 0.183 > 0.05$, taigi negalima atmesti H_0 hipotezės, kad $\beta = 0$. Bet ir priėmus šią hipotezę,

galima tarti, kad aukso kainos mažai priklauso nuo rinkos svyravimų. Laisvasis narys šikart -0.011 ir p -reikšmė rodo, kad jis reikšmingas. Toks rezultatas kiek prieštarauja CAPM logikai - rinkos akcijų vertėms nesikeičiant, aukso rizikos premija neigiama. Galbūt tai gautų reikšti, kad dieninis aukso pelningumas itin nedidelis. $R^2 = 0.0007$ - itin maža reikšmė, patvirtinanti, kad rinka beveik nepaaiškina aukso kainų pokyčių, taigi visa aukso pelningumo rizika sisteminė - priklauso nuo kitų desnių/charakteristikų.

5.1 Sudarytų modelių liekanų tikrinimas

Liekanos turi būti homoskedastiškos, ne autokoreliuotos ir pasiskirsčiusios pagal normalųjį skirstinį.



10 pav.: Aukso modelio liekanos nėra heteroskedastiskos

Patikrinsime, ar liekanos turi slenkantį vidurki.

aktyvas	koef. prieš ankstinį	$p - value$
Microsoft Corp.	-2.293e-02	0.252
Apple Inc.	0.0337889	0.155
Gold	0.0360663	0.0716

Visuose modeliuose pirmos eilės liekanų ankstiniai nereikšmingi.

Autokoreliacijai patikrinti naudosime Durbin-Watson testą:

<i>aktyvas</i>	<i>D – W statistika</i>	<i>–value</i>
Microsoft Corp.	2.04577	0.24
Apple Inc.	1.97393	0.54
Gold	1.927601	0.076

Liekanos nėra autokoreliuotos su savo pirmos eilės ankstiniais.

Normalumui tikrinti naudosime Jarque-Bera arba Kolmogorov-Smirnov testą.

<i>aktyvas</i>	X^2	<i>p – value</i>
Microsoft Corp.	8683.798	< 2.2e-16
Apple Inc.	3384.751	< 2.2e-16
Gold	1593.331	< 2.2e-16

P-reikšmės testuose rodo, kad liekanos nėra pasiskirsčiusios pagal normalųjį skirstinį. Galbūt liekanų pasiskirstymas reiškia, kad rinkos akcijų kainų pokyčiai mažai sutampa su įmonių akcijų vertės pakitimais.

6 Optimalaus portfelio paieška

6.1 Portfeliai iš dviejų aktyvų

Iš pradžių ieškosime optimalių portfelių tarp dviejų aktyvų. Formulė [?]

$$a^* = \frac{\sigma_y^2 - r_{xy}\sigma_x\sigma_y}{\sigma_x^2 + \sigma_y^2 - 2r_{xy}\sigma_x\sigma_y}$$

randa optimaliausią įmonės x akcijų procentą portfelyje. Dar pakombinuosime aktyvus ir nerizikingus išdo vekselius - kokią dalį portfelyje turėtų sudaryti aktyvas ir išdo vekselis. Skaičiavimai su R programa pateikti priede (1-oje skiltyje).

Žymėjimai:

P #1 - Apple Inc. akcijų ir aukso portfelis

P #2 - Apple Inc. ir Microsoft Corp. akcijų portfelis

P #3 - Microsoft Corp. ir auksas

P #4 - Apple Inc. ir nerizikingas aktyvas (išdo vekselis)

P #5 - Microsoft Corp. ir nerizikingas aktyvas

P #6 - Auksas ir nerizikingas aktyvas

	P #1	P #2	P #3	P #4	P #5	P #6
Apple Inc.	18,83 %	25,08 %		0,041 %		
Microsoft Corp.		74,92 %	28,88 %		0,076 %	
Auksas	81,17 %		71,12 %			1,96 %
Vekselis				99,59 %	99,24 %	98,04 %
Gražos	0.00099	0.00060	0.00062	0.00186	0.00185	0.00184
Rizika (s.d.)	0.0104	0.0180	0.0096	0.0017	0.0017	0.0017

1 lentelė: Portfelius sudarančių aktyvų procentai, jų gražos ir rizika

Aukso ir Apple Inc. portfelyje - 81,17 % aukso ir 18,83 % Apple akcijų

Microsoft Corp. ir Apple Inc. portfelyje - 74,92 % Microsoft Corp. akcijų
25,08 % Apple Inc. akcijų

Aukso ir Microsoft Corp. portfelyje - 71,12 % aukso ir 28,88 % Microsoft
akcijų


Visoms trims kombinacijoms su nerizikingu aktyvu tiek rizika, tiek grąža
yra vienodos, o išdo vekselis sudaro beveik visą portfelį.

Pataisymas: šiaip jau JAV išdo vekselių diskonto norma ilgą laiką buvo
gan aukšta ir viršijo 1%. Tačiau po 2008-ųjų metų rugsėjo 15 d. vekselių
diskonto norma nukrito nuo 1.35 iki 0.28 ir vėliau tiek nebepakilo iki 2011-
ųjų vasaros. Todėl būtų naudinga patikrinti optimalias vekselių ir aktyvų
kombinacijas, kai vekselių pelningumas nėra toks didelis.

	P # 4	P # 5	P # 6
Apple Inc.	0,04 %		
Microsoft Corp.		0,00 %	
Auksas			0,04 %
Vekselis	99,96 %	100 %	99,96 %
Gražos	0.001860	0.001860	0.001860
Rizika (stand. nuokrypis)	0.00167	0.00167	0.001669

2 lentelė: Portfelį iš nerizikingo ir rizikingo aktyvo grąžos ir rizika


Deja, išdo vekselių procentai portfeliuose nepakito labai smarkiai, grąžos
ir standartiniai nuokrypiai liko beveik tokie patys, todėl liksime prie pradinių
kombinacijų. Galbūt rezultatai nepasikeitė dėl nuo 2008 m. sumažėjusio
vekselio ir padidėjusio įmonių standartinio nuokrypio.



11 pav.: Iliustracija: dviejų aktyvų kombinacijų rizika ir grąžos

Iš šių kreivių galima matyti, jog net optimalus portfelis, sudarytas iš Apple Inc. ir Microsoft Corp. akcijų turi daug didesnę riziką ir tokią pat grąžą, kaip ir iš aukso bei Microsoft Corp. akcijų sudarytas portfelis. O vos padidinus riziką, iš Apple Inc. ir aukso akcijų sudaryto portfelio, galima gauti didesnę grąžą. Todėl optimaliausias pasirinkimas tarp portfelių, sudarytų iš dviejų aktyvų, yra Apple Inc. ir aukso akcijų kombinacija.

6.2 Trijų aktyvų portfelis



12 pav.: Portfelio, sudaryto iš Apple, Microsoft ir aukso rizikos ir grąžos kombinacijos

Pav.: norint turėti portfelį su mažiausia rizika, reikėtų rinktis portfelio kombinaciją [?], grafike esančią kairiausiai. Kiti portfelio pasirinkimai priklauso nuo vartotojo rizikos preferencijos.

Apytiksliai aktyvų svoriai optimaliame portfelyje, kai $i=8$ ir $j=3$:

$$0.1 \times (i - 1) \times \text{Microsoft} + 0.1 \times (j - 1) \times \text{Auksas} + (1 - (i - 1) - (j - 1)) \times 0.1 \times \text{Apple}$$

Portfelio aktyvų svorius, kai aktyvų yra n (šiuo atveju $n = 3$) nėra lengva rasti, todėl pabandykime pritaikyti dviejų aktyvų optimalaus portfelio formulę: iš ankstesnio poskyrio turime optimalius svorius tarp dviejų aktyvų, dabar ieškome optimalios proporcijos tarp portfelio ir trečio aktyvo.

Portfelių žymėjimai:

P # 7 = optimalus aukso ir Apple Inc. akcijų portfelis ir Microsoft Corp. akcijos

P #8 = optimalus Microsoft Corp. ir Apple Inc. akcijų portfelis ir auksas

P #9 = optimalus Microsoft Corp. akcijų ir aukso portfelis ir Apple Inc. akcijos.

	Apple Inc.	Microsoft Corp.	Auksas	Gražos	Rizika (s.d.)
P # 7	15.18 %	19.41 %	65.41 %	0.0008311881	0.009586881
P # 8	7.764768 %	23.19523 %	69.04 %	0.0007334121	0.009427794
P # 9	6.478507 %	27.00901 %	66.51249 %	0.0006976978	0.009455108

3 lentelė: Portfeliai iš trijų aktyvų

Mažiausią standartinį nuokrypį, t.y. riziką turi aštuntas portfelis. Jį ir pasirinksiame. Portfelio konstravimo kodas su R paketu pateiktas priede (Nr. 4).

Kombinacija su izdo vekseliais ir II portfelio:

P # 10 = 97,04 % * izdo-vekselis + 2,96 % * portfelis2

```
> portfolio = 0.232 * microsoft[-891] + 0.0776 * apple + 0.6904 *
+   gold[-891]
> (var(portfolio) - cor(portfolio, rkfree[-891]) * sd(rkfree) *
+   sd(portfolio))/(var(rkfree) + var(portfolio) - 2 * cor(portfolio,
+   rkfree[-891]) * sd(rkfree) * sd(portfolio))
```


[1] 0.970406

	β	Gražos
Apple Inc.	1.0291	0.0018077
Microsoft Corp.	1.0047	0.000197
Auksas	-0.03864	0.0007931
Vekselis	-0.0004271	0.00186
P 1	0.16243	0.000984
P 2	1.0111	0.00060198
P 3	0.26268	0.00062093
P 4	0.2864	0.000733

4 lentelė: Aktyvų ir portfelių priklausomybė nuo rinkos svyravimų (β) ir jų pelningumas

β parodo, kaip įmonės akcijų ar portfelio rizikos premijos reaguoja į rinkos svyravimus: kuo didesnė β , tuo aktyvas nestabilesnis ir rizikingesnis.

Pateikta lentelė su įmonių, aukso bei portfelių β koeficientais ir jų pelningumais.



13 pav.: Rinkos, izdo vekselių ir įmonių β ir ją atitinkantis gražų vidurkis

Iš lentelės investuotojas gali pasirinkti sau patraukliausią investavimo būdą: jei investuotojas nori gauti itin dideles gražas, ir visiškai nekreipia dėmesio į įmonės priklausomybę nuo rinkos svyravimų, jis rinktųsi investiciją į Apple Inc. akcijas. Kita vertus, turimi empiriniai duomenys rodo, jog JAV izdo vekselio graža yra itin didelė, o rizika ir priklausomybė nuo rinkos itin mažos, todėl vienareikšmiškai galima tarti, kad protingiausia ir naudingiausia investuoti į JAV trisdešimties dienų izdo vekselius.

6.3 Optimaliausių portfelių modeliai

Kandangi jau sudarėme optimaliausias kombinacijas tarp dviejų aktyvų ir pasirinkome trijų aktyvų portfelio svorius, galime sudaryti CAPM regresinius modelius ir pažiūrėti, kaip portfelių pelningumas priklauso nuo rinkos svyravimų. R kodas pateiktas priede.

Regresiniai modeliai:

Modelis 1: Portfelis-1 = $\alpha + \beta \times \text{Rinkos rizikos premija}$

Modelis 2: Portfelis-2 = $\alpha + \beta \times \text{Rinkos rizikos premija}$

Modelis 3: Portfelis-3 = $\alpha + \beta \times \text{Rinkos rizikos premija}$

Modelis 4: Portfelis-4 = $\alpha + \beta \times \text{Rinkos rizikos premija}$

Čia:

Portfelis-1 = 81,17 % aukso + 18,83 % Apple Inc. akciju

Portfelis-2 = 74,92 % Microsoft Corp. + 25,08 % Apple Inc. akciju

Portfelis-3 = 71,12 % aukso + 28,88 % Microsoft Corp. akciju

Portfelis-4 = 7.764768 % Apple Inc. + 23.19523 % Microsoft Corp. + 69.04 % aukso.

	α	β	R^2
Modelis 1	-0.0005723	0.1747229	0.05161
(p-reikšmes)	(0.00549)	(0)	
Modelis 2	0.0004989	1.0097165	0.5831
(p-reikšmes)	(0.0336)	(0)	
Modelis 3	-0.0007624	0.2735671	0.1469
(p-reikšmes)	(0)	(0)	
Modelis 4	-0.0006102	0.2967395	0.1787
(p-reikšmes)	(0.00004)	(0)	

5 lentelė: Visų modelių laisvieji nariai, β ir R^2

Pirmojo modelio koeficientas $\beta=0.17$, tai reiškia, kad portfelio aktyvų svyravimai mažai priklauso nuo rinkos akcijų kainų svyravimų, taigi portfelis gan patikimas. Laisvasis narys nereikšmingas, todėl galime jį prilyginti

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0006	0.0002	-2.78	0.0055
mrp[-891]	0.1747	0.0150	11.66	0.0000

6 lentelė: Pirmojo regresinio modelio įvertiniai

nuliui, kaip ir ankstesnėse interpretacijose, tai reiškia, kad portfelio rizikos premija lygi nuliui, jei rinkos rizikos premija nekinta. Mažas R^2 rodo, jog tik 5% rinkos duomenų paaiškina portfelio akcijų kainų pokyčius, taigi portfelis turi didelį procentą nesisteminės rizikos.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0005	0.0002	2.13	0.0336
mrp[-891]	1.0097	0.0171	59.09	0.0000

7 lentelė: Antrojo regresinio modelio įvertiniai

Antrojo modelio $\beta = 1$, todėl portfelio aktyvų svyravimai judės proporcingai su rinkos akcijų kainų svyravimais. Pakankamai didelis $R^2=58\%$ reiškia, kad tiek procentų rinkos duomenų paaiškina šio portfelio aktyvų pelningumo svyravimus. Nuosmukio laikotarpiu tai ne pats geriausias portfelis, bet pakilimo metu gali būti gan pelningas.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0008	0.0002	-4.21	0.0000
mrp	0.2736	0.0132	20.74	0.0000

8 lentelė: Trečiojo regresinio modelio įvertiniai

Trečiame modelyje $\beta=0.27$, taigi rinkos akcijų kainoms pakilus arba nukritus 1%, portfelio aktyvų rizikos premijos proporcingai pakis daugiau nei ketvirčiu. P-reikšmė prie laisvojo nario rodo, kad jis reikšmingas ir yra neigiamas. Taigi rinkos akcijų rizikos premijoms nekintant, investuotojas iš portfelio gauna nuostolingą rizikos premiją (dėl didesnės išdo vekselio gražos). Tad rinkos akcijų kainoms nekintant, pelningiau investuoti į išdo vekselius, ne tik į šį portfelį.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0006	0.0002	-3.49	0.0005
mrp[-891]	0.2967	0.0127	23.31	0.0000

9 lentelė: Ketvirtojo regresinio modelio įvertiniai

Trijų aktyvų kombinacijos portfelis panašus į aukso ir Microsoft Corp. portfelį. Čia $\beta=0.29$, taigi rinkai susvyravus 1%, portfelio akcijos pakils arba nukris trečdaliu procento. Laisvasis narys vėl neigiamas ir reikšmingas, taigi rinkos akcijų pelningumui nekintant, investuotojo rizikos premija neigiamą. $R^2=0.17$, taigi 17% rinkos duomenų paaiškina portfelio rizikos premijų svyravimus.

Apžvelgus rezultatus, galima daryti išvadą, jog krizės laikotapiu, kai rinkos akcijų kainos ir pelningumas krenta, saugiau investuoti į pirmą portfelį iš Apple Inc. akcijų ir aukso. Tačiau rinkos pakilimo laikotarpiu, antras portfelis iš Microsoft Corp. ir Apple Inc. akcijų gali būti pelningesnis už pirmąjį.

7 Rezultatai ir išvados

8 Naudota literatūra ir kiti šaltiniai

Literatūra

- [1] Thomas E. Copeland, J. Fred Weston: *Financial theory and corporate policy*, Addison-Wesley Publishing Company, (2004)
- [2] Ernst R. Berndt: *The Practice of Econometrics: Classic and Contemporary*, Prentice Hall, (1991)
- [3] Dimitrios Asteriou: *Applied econometrics*, Palgrave macmillian, (2006)
- [4] http://en.wikipedia.org/wiki/Discount_rate
- [5] <http://wikiposit.org/w?filter=Finance>

A Pirmas priedas

Aprašomoji statistika:

```
> mean(rkfree)
```

```
[1] 0.00186004
```

```
> mean(market)
```

```
[1] 0.0001173288
```

```
> mean(microsoft)
```

```
[1] 0.0001968397
```

```
> mean(apple)
```

```
[1] 0.001807715
```

```
> mean(gold)
```

```
[1] 0.0007931419
```

```
> mean(mrp)
```

```
[1] -0.001742711
```

```
> mean(microsoftrp)
```

```
[1] -0.001663201
```

```
> mean(applerp)
```

```
[1] -5.20737e-05
```

```
> mean(goldrp)
```

```
[1] -0.001066898
```

```
> var(rkfree)
```

```

[1] 2.789252e-06
> var(market)
[1] 0.0001827668
> var(microsoft)
[1] 0.0003574371
> var(apple)
[1] 0.0006370941
> var(gold)
[1] 0.0001357824
> var(mrp)
[1] 0.0001857122
> var(microsoftrp)
[1] 0.0003601065
> var(applerp)
[1] 0.000639531
> var(goldrp)
[1] 0.0001384164
> sd(rkfree)
[1] 0.001670105
> sd(market)
[1] 0.01351913

```

```
> sd(microsoft)
[1] 0.01890601
> sd(apple)
[1] 0.02524072
> sd(gold)
[1] 0.01165257
> sd(mrp)
[1] 0.01362763
> sd(microsoftrp)
[1] 0.01897647
> sd(applerp)
[1] 0.02528895
> sd(goldrp)
[1] 0.01176505
> cor(market, microsoft)
[1] 0.7184425
> cor(market[-891], apple)
[1] 0.5511114
> cor(market, gold)
[1] -0.04482454
> cor(mrp, microsoftrp)
[1] 0.7209318
> cor(mrp[-891], applerp)
[1] 0.5534901
> cor(mrp, goldrp)
[1] -0.0266428
```

B Antras priedas

Modeliai:

```
> microsoftmod = lm(microsoftrp ~ mrp)
> applemod = lm(applerp ~ mrp[-891])
> goldmod = lm(goldrp ~ mrp)
> summary(microsoftmod)
```

Call:

```
lm(formula = microsoftrp ~ mrp)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.114489	-0.006098	-0.000315	0.005991	0.088079

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0000863	0.0002652	0.325	0.745
mrp	1.0038977	0.0193079	51.994	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01315 on 2498 degrees of freedom
Multiple R-squared: 0.5197, Adjusted R-squared: 0.5196
F-statistic: 2703 on 1 and 2498 DF, p-value: < 2.2e-16

```
> summary(applemod)
```

Call:

```
lm(formula = applerp ~ mrp[-891])
```

Residuals:

Min	1Q	Median	3Q	Max
-0.135080	-0.010883	-0.000986	0.010278	0.139434

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0017347	0.0004248	4.083	4.58e-05 ***


```
mrp[-891] 1.0269695 0.0309249 33.209 < 2e-16 ***
```

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.02107 on 2497 degrees of freedom  
Multiple R-squared: 0.3064, Adjusted R-squared: 0.3061  
F-statistic: 1103 on 1 and 2497 DF, p-value: < 2.2e-16
```

```
> summary(goldmod)
```

```
Call:
```

```
lm(formula = goldrp ~ mrp)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-0.071932	-0.005851	0.000178	0.006454	0.071524

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0011070	0.0002372	-4.667	3.21e-06 ***
mrp	-0.0230014	0.0172673	-1.332	0.183

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.01176 on 2498 degrees of freedom  
Multiple R-squared: 0.0007098, Adjusted R-squared: 0.0003098  
F-statistic: 1.774 on 1 and 2498 DF, p-value: 0.183
```

```
> summary(dynlm(ts(applerp) ~ ts(mrp) + L(ts(applemod$res), 1)))
```

```
Time series regression with "ts" data:
```

```
Start = 2, End = 2499
```

```
Call:
```

```
dynlm(formula = ts(applerp) ~ ts(mrp) + L(ts(applemod$res), 1))
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-0.179507	-0.013359	-0.000553	0.013549	0.131190

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.0004459	0.0005040	0.885	0.376
ts(mrp)	0.2883804	0.0366877	7.860	5.65e-15 ***
L(ts(applemod\$res), 1)	0.0337889	0.0237419	1.423	0.155

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02499 on 2495 degrees of freedom
Multiple R-squared: 0.02478, Adjusted R-squared: 0.024
F-statistic: 31.7 on 2 and 2495 DF, p-value: 2.545e-14

```
> summary(dynlm(ts(microsoftrp) ~ ts(mrp) + L(ts(microsoftmod$res),  
+ 1)))
```

Time series regression with "ts" data:
Start = 2, End = 2500

Call:

```
dynlm(formula = ts(microsoftrp) ~ ts(mrp) + L(ts(microsoftmod$res),  
1))
```

Residuals:

Min	1Q	Median	3Q	Max
-0.114434	-0.006106	-0.000373	0.006017	0.088020

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	8.717e-05	2.653e-04	0.329	0.743
ts(mrp)	1.004e+00	1.932e-02	51.999	<2e-16 ***
L(ts(microsoftmod\$res), 1)	-2.293e-02	2.002e-02	-1.146	0.252

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01316 on 2496 degrees of freedom
Multiple R-squared: 0.52, Adjusted R-squared: 0.5196
F-statistic: 1352 on 2 and 2496 DF, p-value: < 2.2e-16

```
> summary(dynlm(goldrp ~ mrp + L(ts(goldmod$res), 1)))
```

Time series regression with "numeric" data:

Start = 1, End = 2499

Call:

```
dynlm(formula = goldrp ~ mrp + L(ts(goldmod$res), 1))
```

Residuals:

Min	1Q	Median	3Q	Max
-0.072581	-0.005880	0.000178	0.006435	0.072343

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0011091	0.0002372	-4.677	3.07e-06 ***
mrp	-0.0236453	0.0172664	-1.369	0.1710
L(ts(goldmod\$res), 1)	0.0360663	0.0200098	1.802	0.0716 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01176 on 2496 degrees of freedom

Multiple R-squared: 0.00201, Adjusted R-squared: 0.00121

F-statistic: 2.513 on 2 and 2496 DF, p-value: 0.08123

```
> durbinWatsonTest(microsoftmod, max.lag = 1)
```

lag	Autocorrelation	D-W Statistic	p-value
1	-0.02291682	2.04577	0.264

Alternative hypothesis: rho != 0

```
> durbinWatsonTest(applemod, max.lag = 1)
```

lag	Autocorrelation	D-W Statistic	p-value
1	0.01299961	1.97393	0.524

Alternative hypothesis: rho != 0

```
> durbinWatsonTest(goldmod, max.lag = 1)
```

lag Autocorrelation D-W Statistic p-value

1 0.03604061 1.927601 0.064

Alternative hypothesis: rho != 0

```
> jarque.bera.test(microsoftmod$res)
```

Jarque Bera Test

data: microsoftmod\$res

X-squared = 8683.798, df = 2, p-value < 2.2e-16

```
> jarque.bera.test(applemod$res)
```

Jarque Bera Test

data: applemod\$res

X-squared = 3384.751, df = 2, p-value < 2.2e-16

```
> jarque.bera.test(goldmod$res)
```

Jarque Bera Test

data: goldmod\$res

X-squared = 1593.331, df = 2, p-value < 2.2e-16

C Trečias priedas

Portfeliai:

Aktyvo x dalis portfelyje iš dviejų aktyvų


	[,1]	[,2]	[,3]
[1,]	0.8116744	0.7491511	0.7111582

	vek1	vek2	vek3
[1,]	0.9959148	0.9924209	0.9804096

Iždo vekselio procentas portfelyje iš dviejų aktyvų

	[,1]	[,2]	[,3]
[1,]	0.999665	1.000066	0.9996887

Apytikslės koeficientų reikšmės portfelyje iš dviejų įmonių



14 pav.: ...

(gal nereikia) Iliustracija: pagal grafikus rinktis ta skaičiu, ties kuriuo standartinis nuokrypis mažiausias, jį įstatyti vietoje i .

$$\text{optimaliausias portfelis} = imone1 \times i \times 0.1 + imone2 \times (1 - i \times 0.1)$$

$$0.1 \times (i - 1) \times Auksas + (1 - 0.1 \times (i - 1)) \times Microsoft$$

$$0.1 \times (i - 1) \times Apple + (1 - 0.1 \times (i - 1)) \times Microsoft$$

$$0.1 \times (i - 1) \times Apple + (1 - 0.1 \times (i - 1)) \times Auksas$$

Trijų aktyvų portfelio paieška

I variantas:

$$> folio = 0.8117 * gold[-891] + 0.1883 * apple$$

$$\begin{aligned} > & (var(microsoft) - cor(microsoft[-891], folio) * sd(folio) * sd(microsoft)) / (var(folio) + \\ & + var(microsoft) - 2 * cor(microsoft[-891], folio) * sd(folio) * \\ & + sd(microsoft)) \end{aligned}$$

$$[1] 0.8059366$$

80,59 % folio ir 19,41 % microsoft

80.59* 0.8117 aukso

80.59* 0.1883 apple

```
> sd((65.41 * gold[-891] + 15.18 * apple + 19.41 * microsoft[-891])/100)
```

```
[1] 0.009586881
```

II variantas

```
> folio = 0.7492 * microsoft[-891] + 0.2508 * apple
```

```
> (var(folio) - cor(folio, gold[-891]) * sd(gold) * sd(folio))/(var(gold) +  
+ var(folio) - 2 * cor(folio, gold[-891]) * sd(gold) * sd(folio))
```

```
[1] 0.6904081
```

69.04 % aukso ir 30.96 % folio

30.96* 0.7492 = 23.19523 % microsoft

30.96* 0.2508 = 7.764768 % apple

```
> sd((23.19523 * microsoft[-891] + 7.764768 * apple + 69.04 * gold[-891])/100)
```

```
[1] 0.009427794
```

III variantas

```
> folio = 0.2888 * microsoft + gold * 0.7112
```

```
> (var(folio) - cor(folio[-891], apple) * sd(apple) * sd(folio))/(var(apple) +  
+ var(folio) - 2 * cor(folio[-891], apple) * sd(apple) * sd(folio))
```

```
[1] 0.06478507
```

6.478507 % apple

93.5215 * 0.2888 = 27.00901 % microsoft

93.5215 * 0.7112 = 66.51249 % aukso

```
> sd((6.478507 * apple + 27.00901 * microsoft[-891] + 66.51249 *  
+ gold[-891])/100)
```

```
[1] 0.009455108
```

Portfelių regresinių modelių R kodas

```
> summary(goldapplemod)
```

```

Call:
lm(formula = goldapplerp ~ mrp[-891])

Residuals:
    Min       1Q   Median       3Q      Max
-0.065798 -0.005279  0.000247  0.005839  0.063207

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0005723  0.0002059  -2.779  0.00549 **
mrp[-891]    0.1747229  0.0149894  11.656 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01021 on 2497 degrees of freedom
Multiple R-squared:  0.05161,    Adjusted R-squared: 0.05123
F-statistic: 135.9 on 1 and 2497 DF,  p-value: < 2.2e-16

> summary(microapplemod)

Call:
lm(formula = microapplerp ~ mrp[-891])

Residuals:
    Min       1Q   Median       3Q      Max
-0.082629 -0.006268 -0.000240  0.006055  0.066101

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0004989  0.0002347   2.126  0.0336 *
mrp[-891]    1.0097165  0.0170871  59.092 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01164 on 2497 degrees of freedom
Multiple R-squared:  0.5831,    Adjusted R-squared: 0.5829
F-statistic: 3492 on 1 and 2497 DF,  p-value: < 2.2e-16

> summary(goldmicromod)

```

```

Call:
lm(formula = goldmicrorp ~ mrp)

Residuals:
    Min       1Q   Median       3Q      Max
-0.050394 -0.004731  0.000146  0.005137  0.057667

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0007624  0.0001812  -4.207 2.68e-05 ***
mrp          0.2735671  0.0131925  20.737 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.008987 on 2498 degrees of freedom
Multiple R-squared:  0.1469,    Adjusted R-squared:  0.1465
F-statistic:  430 on 1 and 2498 DF,  p-value: < 2.2e-16

> summary(goldmicroapplemod)

Call:
lm(formula = goldmicroapplerp ~ mrp[-891])

Residuals:
    Min       1Q   Median       3Q      Max
-0.050221 -0.004560  0.000177  0.004888  0.055819

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0006102  0.0001749  -3.489 0.000492 ***
mrp[-891]    0.2967395  0.0127287  23.313 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.008671 on 2497 degrees of freedom
Multiple R-squared:  0.1787,    Adjusted R-squared:  0.1784
F-statistic: 543.5 on 1 and 2497 DF,  p-value: < 2.2e-16

```

Portfelijų regresijos R kodas


```

> goldapple = 0.8117 * gold[-891] + 0.1883 * apple
> microapple = 0.7492 * microsoft[-891] + 0.2508 * apple
> goldmicro = 0.7112 * gold + 0.2888 * microsoft
> goldmicroapple = 0.232 * microsoft[-891] + 0.0776 * apple + 0.6904 *
+   gold[-891]
> goldapplerp = goldapple - rkfree[-891]
> microapplerp = microapple - rkfree[-891]
> goldmicrorp = goldmicro - rkfree
> goldmicroapplerp = goldmicroapple - rkfree[-891]
> goldapplemod = lm(goldapplerp ~ mrp[-891])
> microapplemod = lm(microapplerp ~ mrp[-891])
> goldmicromod = lm(goldmicrorp ~ mrp)
> goldmicroapplemod = lm(goldmicroapplerp ~ mrp[-891])
> microapple.table = xtable(microapplemod)
> goldapple.table = xtable(goldapplemod)
> goldmicro.table = xtable(goldmicromod)
> goldmicroapple.table = xtable(goldmicroapplemod)

```